

UNIVERSIDAD DE COLIMA

Facultad de Ingeniería Mecánica y Eléctrica

Visión Artificial y Registro Multimodal para Comunicación y Rehabilitación en Personas con Parálisis Cerebral

Tesis en desarrollo - versión al 80%

Presenta: José Antonio Benavides Ortega

Asesores: Dr. Walter Alexander Mata López; Dr. José Luis Álvarez Flores

Estado del documento: tesis en desarrollo al 80%

Fecha: Colima, Col., México, 2026



UNIDAD I.- INTRODUCCIÓN

1.1.- Resumen

La Parálisis Cerebral es una condición neurológica que, en muchos casos, impide que las personas afectadas puedan comunicarse mediante el habla. Esto no significa que no tengan nada que decir: simplemente su cuerpo no les permite expresarlo de forma convencional. Este proyecto propone una herramienta tecnológica que lee las expresiones del rostro —si la persona parece tranquila, contenta o con dolor— y las convierte en un mensaje de voz o una imagen que el cuidador puede entender de inmediato, usando únicamente una cámara web ordinaria y una computadora común. El sistema funciona en tres pasos. Primero, un programa llamado MediaPipe Face Mesh —desarrollado por Google— detecta en tiempo real hasta 478 puntos clave del rostro: los extremos de los labios, el arco de las cejas, los párpados, las comisuras. A partir de esos puntos se calculan medidas geométricas del rostro, como que tan abierta está la boca o si las comisuras suben al sonreír. Segundo, un clasificador —un programa de aprendizaje automático que aprende a reconocer patrones— usa esas medidas para determinar si la expresión corresponde a alegría, dolor o estado neutro. Tercero, una interfaz gráfica traduce esa detección en un mensaje de voz o un pictograma visible para el cuidador, personalizable según las necesidades de cada persona. El prototipo desarrollado responde en menos de 34 milésimas de segundo —prácticamente instantáneo— y funciona sin necesidad de una tarjeta gráfica especializada. Una parte importante del trabajo fue descubrir que los umbrales de detección no son iguales para todos: cada persona necesita una calibración breve de dos minutos para que el sistema aprenda sus expresiones particulares. Este hallazgo, junto con el prototipo funcional, constituye la aportación central de este proyecto y la base metodológica para extenderlo en el futuro a personas con Parálisis Cerebral de cualquier edad con datos clínicos reales.

1.2.- Planteamiento del problema

La Parálisis Cerebral (PC) es una condición neurológica que frecuentemente conlleva dificultades motoras orofaciales graves, resultando en problemas severos para la comunicación verbal en personas de cualquier edad. Kristoffersson et al. (2020) documentan que existe una correlación directa entre la función motora y la capacidad comunicativa, situando a estas personas en alto riesgo de aislamiento social al no poder expresar necesidades básicas, sentimientos o dolor a sus cuidadores. Los sistemas de Comunicación Aumentativa y Alternativa (CAA) basados en interfaces físicas (tabletas, botones) son frecuentemente inoperables para personas con espasticidad o movimientos involuntarios. La Visión por Computadora emerge como alternativa no invasiva; sin embargo, el desarrollo de sistemas FER confiables para esta población enfrenta dos obstáculos críticos: la escasez de datasets representativos de expresiones atípicas y los requisitos computacionales elevados de las arquitecturas de Deep Learning de vanguardia. Sabater-Gárriz et al. (2024) señalan explícitamente que la falta de muestras representativas impide que los modelos actuales funcionen con suficiente sensibilidad

para expresiones sutiles en PC. Frente a este panorama, la investigación propone responder a la siguiente pregunta:

Pregunta de investigación: ¿Es viable desarrollar un sistema de Reconocimiento de Expresiones Faciales operativo en tiempo real y en hardware de consumo estándar, utilizando landmarks faciales extraídos mediante MediaPipe y clasificadores ligeros entrenados con datasets públicos aumentados, como base metodológica para una futura herramienta de CAA para personas con Parálisis Cerebral?

1.3.- Objetivos y metas

1.3.1.- Objetivo general

Desarrollar, entrenar y evaluar un prototipo funcional de sistema de Reconocimiento de Expresiones Faciales (FER) en tiempo real, basado en la extracción de landmarks faciales con MediaPipe y clasificadores ligeros, que sirva como fundamento técnico y análisis de viabilidad para una herramienta de Comunicación Aumentativa y Alternativa (CAA) orientada a personas con Parálisis Cerebral, ejecutable en hardware de consumo estándar.

1.3.2.- Objetivos específicos

1. Realizar una revisión exhaustiva del estado del arte en sistemas FER aplicados a poblaciones con condiciones neurológicas, con énfasis en arquitecturas ligeras, extracción de landmarks faciales y técnicas de aumentación de datos en contextos de escasez de muestras. 2. Construir un dataset de entrenamiento funcional a partir de fuentes públicas (RAF- DB, CK+), aplicando técnicas de aumentación de datos clásica (rotación, cambio de brillo, recorte, volteo horizontal) para las categorías emocionales definidas: dolor, alegría y neutral. 3. Implementar y comparar clasificadores ligeros para FER: (a) un clasificador sobre vectores de distancias geométricas entre landmarks (SVM, MLP), y (b) fine-tuning de MobileNetV2 sobre imágenes faciales normalizadas, documentando precisión, recall, F1- score y latencia de inferencia para cada enfoque. 4. Integrar el modelo de mejor desempeño en un pipeline de tiempo real utilizando OpenCV y MediaPipe, garantizando una latencia de procesamiento por fotograma inferior a 500ms en hardware de consumo estándar (CPU, sin GPU dedicada). 5. Diseñar y construir una interfaz de usuario gráfica (GUI) intuitiva que traduzca las expresiones detectadas en mensajes de voz o pictogramas personalizables, con énfasis en la usabilidad para cuidadores sin formación técnica. 6. Elaborar un análisis de viabilidad clínica documentado que identifique las limitaciones del sistema en el contexto de expresiones atípicas de PC y proponga una hoja de ruta metodológica para la extensión futura del sistema a datos clínicos reales.

1.3.3.- Metas

Las siguientes metas constituyen los resultados concretos y cuantificables esperados al concluir el proyecto:

ID	Meta	Criterio de Éxito (Cuantitativo)
M1	Pipeline de Extracción de Landmarks	

Implementación funcional de MediaPipe Face Mesh extrayendo 478 landmarks en tiempo real a ≥ 25 FPS en hardware de consumo.

M2 Dataset etiquetado y aumentado Generación de un dataset con al menos 3 categorías emocionales (dolor, alegría, neutral) utilizando RAF-DB/CK+ con aumentación clásica documentada. M3 Modelo FER ligero Clasificador (MobileNetV2 o SVM sobre landmarks) con precisión $\geq 80\%$ en validación cruzada y latencia de inferencia $< 500\text{ms}$. M4 Interfaz CAA funcional Prototipo de GUI operativa que traduce expresión detectada a mensaje de voz o pictograma, personalizable por el cuidador. M5 Análisis de viabilidad clínica Documento de limitaciones y hoja de ruta metodológica para la extensión del sistema a datos reales de personas con PC.

1.4.- Justificación

Impacto social y humanitario: La incapacidad de comunicarse es una de las barreras más profundas para la inclusión. Sennott et al. (2019) destacan que la integración de inteligencia artificial en sistemas de CAA puede transformar la interacción diaria, adaptando el sistema al usuario. Este proyecto busca proporcionar una herramienta de comunicación no invasiva para personas con PC, mejorando su autonomía y calidad de vida. Relevancia tecnológica y viabilidad práctica: El enfoque adoptado prioriza la ejecutabilidad en hardware de consumo estándar. MediaPipe Face Mesh opera en tiempo real incluso sobre CPU, eliminando la dependencia de GPU de alto rendimiento (Google AI, 2020). Los clasificadores propuestos (SVM, MLP, MobileNetV2) son entrenables en entornos universitarios convencionales con datasets públicos disponibles gratuitamente. Aportación metodológica: La comparativa sistemática entre clasificadores sobre landmarks geométricos versus clasificadores sobre imagen normalizada constituye una contribución documentada al campo, especialmente relevante en el contexto de expresiones atípicas donde los datasets estándar son insuficientes (Gaya-Morey et al., 2024; Sabater-Gárriz et al., 2024). El análisis de viabilidad resultante servirá como fundamento para investigaciones futuras que cuenten con acceso a datos clínicos reales. Escalabilidad futura: El diseño modular del sistema permite que, una vez disponibles datos reales de personas con PC, el pipeline pueda ser re-entrenado sin modificaciones arquitectónicas. Esto posiciona el proyecto como una base metodológica sólida para investigación aplicada de mayor alcance.

1.5.- Hipótesis

Hipótesis de Trabajo (H_1): Si se implementa un pipeline de Reconocimiento de Expresiones Faciales basado en la extracción de landmarks faciales mediante MediaPipe Face Mesh y se entrena un clasificador ligero (MobileNetV2 con fine-tuning o SVM sobre vectores de distancias geométricas) utilizando datasets públicos aumentados con técnicas de aumentación clásica, entonces será posible desarrollar un sistema FER que alcance una precisión superior al 80% en validación y una latencia de inferencia inferior a 500ms en hardware de consumo estándar, demostrando la viabilidad técnica del enfoque como base para una herramienta de CAA accesible para personas con Parálisis Cerebral (Bi et al., 2025; Nan et al., 2022).

Hipótesis Nula (H_0): El uso de landmarks faciales extraídos con MediaPipe como características de entrada para clasificadores ligeros no produce una mejora significativa en la precisión del modelo FER en comparación con las técnicas de aumentación de datos clásica sobre CNN convencionales, resultando en un prototipo que no alcanza los umbrales de fiabilidad ($> 80\%$) ni de eficiencia ($< 500\text{ms}$) necesarios para considerarse una herramienta de comunicación efectiva. Definición de Variables: • Variable Independiente: El tipo de pipeline FER empleado: (a) clasificador sobre landmarks geométricos de MediaPipe versus (b) fine-tuning de MobileNetV2 sobre imagen facial normalizada, ambos entrenados con el mismo dataset aumentado. • Variables Dependientes: ◦ Precisión (Accuracy), Recall y F1-score del modelo en clasificación de las 3 categorías emocionales definidas. ◦ Latencia de inferencia (milisegundos por fotograma) en hardware de consumo estándar. ◦ Calidad y diversidad del dataset generado mediante aumentación clásica, evaluada cuantitativamente.

UNIDAD II.- ESTADO DEL CAMPO Y DEL ARTE

2.1.- Marco Teórico

El marco teórico se fundamenta en tres pilares conceptuales y tecnológicos que soportan el diseño de la investigación: 7. Parálisis Cerebral (PC) y Comunicación Aumentativa y Alternativa (CAA): La PC es una condición que a menudo resulta en dificultades severas de comunicación. Kristoffersson et al. (2020) documentan que la capacidad y el método de comunicación están relacionados con la función motora, y que los métodos de comunicación asistida se utilizan con mayor frecuencia en personas en etapas avanzadas. La CAA busca complementar o reemplazar el habla cuando las vías convencionales están comprometidas. Sennott et al. (2019) argumentan que la integración de IA en CAA permite sistemas adaptativos que se ajustan al usuario en lugar de requerir que el usuario se adapte al sistema. 8. Reconocimiento de Expresiones Faciales (FER) y Extracción de Landmarks: El FER mediante Deep Learning ha avanzado significativamente, con CNN como estándar para la clasificación de imágenes faciales (Yoonessi et al., 2025). MediaPipe Face Mesh, desarrollado por Google, ofrece la extracción en tiempo real de 478 landmarks tridimensionales sobre el rostro sin requerir GPU dedicada, operando incluso sobre CPU a tasas superiores a 25 FPS (Google AI, 2020). Estos landmarks permiten derivar vectores de características geométricas (distancias, ángulos, ratios entre puntos clave) que codifican la expresión facial de manera compacta y eficiente. Sabater-Gárriz et al. (2024) han demostrado el potencial del reconocimiento facial automatizado para la evaluación del dolor en personas con PC, subrayando la necesidad de datasets más extensos y diversos. 9. Aumentación de Datos Clásica en Contextos de Escasez: Ante la limitación de datasets representativos de expresiones atípicas en PC, la aumentación de datos clásica (rotación, cambio de brillo, recorte aleatorio, volteo horizontal, adición de ruido gaussiano) permite incrementar artificialmente la diversidad del conjunto de entrenamiento (Chen et al., 2022). Si bien Chen et al. (2022) documentan las ventajas de las GANs para aumentación médica, la literatura también reconoce que técnicas clásicas bien aplicadas son competitivas cuando el dataset base tiene suficiente variabilidad y las categorías son claramente diferenciables. Este proyecto adopta el enfoque clásico por su menor costo computacional y mayor reproducibilidad en entornos universitarios.

2.1.1.- Arquitecturas Ligeras para FER en Tiempo Real

El éxito de un sistema FER en tiempo real sobre hardware de consumo depende del equilibrio entre capacidad de extracción de características y costo computacional. Este proyecto evalúa dos enfoques complementarios: 10. Clasificadores sobre landmarks geométricos (SVM / MLP): A partir de los 478 landmarks de MediaPipe se derivan vectores de distancias entre puntos clave del rostro (comisuras, cejas, párpados, nariz). Estos vectores de baja dimensionalidad alimentan clasificadores clásicos como Support Vector Machines (SVM) o Perceptrones Multicapa (MLP), cuya inferencia es extremadamente rápida (< 5ms). La ventaja principal es la robustez ante variaciones de iluminación y escala, y la total independencia de GPU. 11. Fine-tuning de MobileNetV2: MobileNetV2 utiliza convoluciones separables en profundidad y cuellos de botella lineales invertidos que reducen drásticamente las

operaciones de multiplicación-acumulación sin sacrificar significativamente la precisión (Nan et al., 2022). Con fine-tuning sobre el dataset aumentado, esta arquitectura opera a latencias aceptables (< 200ms) incluso sobre CPU de gama media, siendo adecuada para el objetivo de tiempo real establecido. La comparativa sistemática entre ambos enfoques sobre el mismo dataset y hardware constituye una de las aportaciones metodológicas centrales de esta investigación.

2.2.- Marco Histórico y Evolución

12. Evolución de la CAA: Los sistemas de CAA han evolucionado desde métodos de baja tecnología hasta soluciones electrónicas complejas, incluyendo interfaces cerebro- computadora (Peters et al., 2022). Sennott et al. (2019) documentan que esta evolución está orientada a sistemas que puedan adaptarse y predecir las necesidades del usuario, reduciendo la carga cognitiva sobre la persona. La integración de IA en CAA es un desarrollo más reciente, orientado a sistemas que puedan adaptarse y predecir las necesidades del usuario (Sennott et al., 2019). Este proyecto se alinea con esta tendencia utilizando visión artificial como canal de entrada no invasivo. 13. Estado del arte en FER para PC: Sabater-Gárriz et al. (2024) desarrollaron un sistema de reconocimiento facial para evaluación del dolor en adultos con PC, concluyendo que un dataset más extenso y diverso podría mejorar la sensibilidad del modelo ante expresiones sutiles. Gaya-Morey et al. (2024) evaluaron enfoques de Deep Learning para FER en personas con discapacidad intelectual, señalando que las expresiones atípicas presentan distribuciones estadísticamente diferentes a las de los datasets estándar. Estos trabajos validan directamente la necesidad de investigación específica en este dominio. 14. Tendencia hacia arquitecturas ligeras y edge computing: La literatura reciente muestra un desplazamiento hacia arquitecturas optimizadas para inferencia en dispositivos de borde. Bi et al. (2025) realizaron una comparativa entre MobileNetV2, VGG-16, ResNet y Swin Transformer para FER, concluyendo que MobileNetV2 ofrece el mejor equilibrio entre precisión y eficiencia computacional para aplicaciones en tiempo real. Este hallazgo respalda la selección arquitectónica de este proyecto, en línea con lo reportado por Nan et al. (2022) sobre el desempeño de arquitecturas MobileNet en tareas de reconocimiento facial con restricciones computacionales.

UNIDAD II-B.- PROFUNDIZACIÓN DEL MARCO TEÓRICO

2.3.- Fundamentos Neurológicos de la Parálisis Cerebral y su Impacto en la

Expresión Facial La Parálisis Cerebral (PC) es un grupo heterogéneo de trastornos del movimiento y la postura, de carácter no progresivo, causados por una lesión o anomalía en el cerebro en desarrollo, generalmente antes, durante o poco después del nacimiento. Su prevalencia global se estima en 1.5 a 4 casos por cada 1,000 nacidos vivos, constituyendo la causa más frecuente de discapacidad motora grave en la infancia (Kristoffersson et al., 2020). La clasificación funcional más utilizada en la práctica clínica es el Sistema de Clasificación de la Función Motora Gruesa (GMFCS), que estratifica la severidad en cinco niveles según la capacidad de desplazamiento y control postural de la persona. La

musculatura orofacial, responsable tanto de la articulación del habla como de la expresión emocional, se ve frecuentemente afectada en la PC, especialmente en los subtipos espástico y discinético. La espasticidad orofacial produce un aumento del tono muscular en reposo que distorsiona la morfología facial basal, dificultando la detección de cambios expresivos relativos a esa línea base idiosincrática. La discinesia, caracterizada por movimientos involuntarios e impredecibles, introduce variabilidad no expresiva en los landmarks faciales que los clasificadores entrenados con datos neurotípicos interpretan erróneamente como expresiones emocionales. Este fenómeno, conocido como ruido motor expresivo, constituye el desafío técnico central que diferencia el FER en PC del FER convencional. Desde la neurociencia cognitiva, se distingue entre la expresión facial voluntaria (corteza motora primaria y área de Broca) y la expresión facial espontánea (sistema límbico y vías extrapiramidales). En personas con PC, la disociación entre ambas vías puede resultar en que la expresión espontánea de dolor o alegría se produzca a través de vías subcorticales relativamente preservadas, incluso cuando el control motor voluntario orofacial está severamente comprometido. Esta disociación es clínicamente relevante porque sugiere que la expresión facial espontánea puede ser una señal diagnósticamente válida incluso en personas con PC grave (Sabater-Gárriz et al., 2024), siempre que los sistemas de reconocimiento estén entrenados para interpretar sus patrones específicos.

2.4.- Comunicación Aumentativa y Alternativa: Fundamentos y Estado

Actual La Comunicación Aumentativa y Alternativa (CAA) abarca un conjunto de estrategias, ayudas técnicas y métodos de intervención cuyo objetivo es compensar, temporal o permanentemente, las deficiencias en la producción y comprensión del lenguaje hablado y escrito. La Sociedad Internacional de CAA (ISAAC) distingue entre sistemas de CAA sin ayuda técnica (gestos, lengua de signos, expresión facial amplificada) y con ayuda técnica, que a su vez se subdividen en sistemas de baja tecnología (tableros de comunicación impresos, libros de pictogramas) y alta tecnología (dispositivos generadores de voz, aplicaciones en tableta, sistemas de seguimiento ocular).

Los sistemas de alta tecnología han experimentado una evolución acelerada en la última década impulsada por la reducción de costos de hardware y los avances en procesamiento del lenguaje natural. Sin embargo, la mayoría de estos sistemas requieren que el usuario tenga control motor suficiente para operar al menos un pulsador o seguir objetos con la mirada, lo que los hace inoperables para personas con PC grave que presentan espasticidad generalizada y alteraciones del control oculomotor. La visión por computadora, y específicamente el reconocimiento de expresiones faciales, emerge como la alternativa más prometedora para este subgrupo de pacientes, al no requerir ningún tipo de control motor voluntario más allá de la expresión facial espontánea. En el contexto latinoamericano, la disponibilidad de sistemas de CAA de alta tecnología está limitada por consideraciones económicas y de infraestructura. Los dispositivos de seguimiento ocular certificados para uso clínico (Tobii Dynavox, Eyegaze Edge) tienen costos que oscilan entre 5,000 y 15,000 USD (Peters et al., 2022), inalcanzables para la mayoría de las familias en contextos de bajos recursos. Esta realidad refuerza la relevancia del enfoque adoptado en esta investigación: un sistema basado en

cámara web estándar, ejecutable en hardware de consumo convencional y con software de código abierto, representa una oportunidad real de democratización tecnológica en el ámbito de la CAA.

2.5.- Reconocimiento de Expresiones Faciales: Evolución Técnica

2.5.1.- De los Sistemas Basados en Reglas a las Redes Neuronales Profundas

El reconocimiento automático de expresiones faciales tiene sus raíces en los trabajos de Ekman y Friesen sobre el Sistema de Codificación de Acciones Faciales (FACS), desarrollado en los años 70, que describe las expresiones faciales en términos de Unidades de Acción (AU) musculares. Los primeros sistemas automáticos de FER intentaban detectar estas AUs mediante reglas geométricas sobre descriptores de puntos fiduciales extraídos manualmente, lo que los hacía extremadamente sensibles a variaciones de pose e iluminación y poco generalizables fuera de entornos de laboratorio controlados. La introducción de las Redes Neuronales Convolucionales (CNN) para FER a partir de 2013, con el trabajo seminal de Goodfellow et al. (2013) en el FER2013 challenge, transformó radicalmente el campo. Las CNN aprenden automáticamente las representaciones jerárquicas más discriminativas de la imagen facial, sin requerir ingeniería de características manual. Arquitecturas como VGG-16, ResNet-50 e InceptionV3 alcanzaron precisiones superiores al 70% en datasets de referencia como AffectNet (450,000 imágenes) y RAF-DB, superando consistentemente a los sistemas basados en reglas. Sin embargo, este rendimiento viene acompañado de un costo computacional que impide su despliegue en dispositivos de borde sin GPU dedicada, lo que motiva la búsqueda de arquitecturas ligeras como MobileNetV2.

2.5.2.- MediaPipe Face Mesh como Infraestructura de Extracción

MediaPipe Face Mesh, desarrollado por Google Research y publicado en 2020, representa un hito en la democratización del FER por su capacidad de extraer 478 landmarks faciales tridimensionales en tiempo real sin requerir hardware especializado.

El pipeline de MediaPipe combina dos redes neuronales ligeras en cascada: un detector de cara basado en BlazeFace —SSD con anchors optimizados para rostros— (Google AI, 2020) (Google AI, 2020), seguido de un estimador de landmarks que opera sobre la región de interés facial recortada. Ambas redes están optimizadas para inferencia en CPU mediante técnicas de cuantización y destilación de conocimiento, logrando una latencia total inferior a 30ms en dispositivos móviles de gama media. La malla facial de 478 puntos proporciona una representación densa de la geometría facial que incluye el contorno facial, las cejas, los párpados, la nariz, los labios, la boca y el iris. A diferencia de los 68 landmarks del modelo de Dlib (ampliamente utilizado antes de MediaPipe), la densidad de la malla de MediaPipe permite derivar características de expresión significativamente más ricas, capturando deformaciones sutiles en regiones como el área nasolabial y la frente que son clínicamente relevantes para la detección de dolor en PC (Sabater-Gárriz et al., 2024).

2.6.- Aumentación de Datos en Visión por Computadora Médica

La escasez de datos etiquetados de calidad es una limitación recurrente en las aplicaciones de visión por computadora en el dominio médico y de la salud. A diferencia de los datasets de fotografía natural (ImageNet, MS-COCO) que cuentan con millones de imágenes etiquetadas, los datasets de expresiones faciales en poblaciones clínicas específicas son órdenes de magnitud más pequeños, debido a las dificultades éticas y logísticas de recopilación de datos con poblaciones vulnerables. La aumentación de datos clásica (transformaciones geométricas y fotométricas) es la estrategia más ampliamente adoptada por su simplicidad computacional y su demostrada efectividad como regularizador implícito. Estudios de ablación han mostrado que la aplicación combinada de rotación, volteo horizontal y ajuste de brillo puede mejorar la precisión de clasificadores CNN en datasets pequeños (Chen et al., 2022) ($N < 5,000$) entre un 3% y un 8% en comparación con el entrenamiento sin aumentación. Técnicas más avanzadas como CutMix (interpolación de parches entre imágenes) y MixUp (interpolación lineal de imágenes y etiquetas) han mostrado mejoras adicionales de 1- 3% con overhead computacional mínimo, y serán evaluadas como extensión opcional en la Fase 2 del proyecto. La aumentación sintética mediante Redes Generativas Antagónicas (GANs) representa la frontera del estado del arte, pero conlleva desafíos significativos: el entrenamiento de GANs de calidad requiere datasets base de al menos 10,000 imágenes y GPU de alto rendimiento, además de introducir el riesgo de artifacts sintéticos que degraden la generalización del clasificador. En el contexto de este proyecto, donde el dataset base es de tamaño moderado y los recursos computacionales son limitados, la aumentación clásica bien calibrada es la opción más apropiada y reproducible, siguiendo la recomendación metodológica de priorizar la reproducibilidad en investigación universitaria.

UNIDAD III.- ANÁLISIS DEL SISTEMA

3.1.- Metodología

El proyecto sigue una metodología de desarrollo iterativa orientada a la investigación aplicada, con énfasis en la reproducibilidad, la documentación de resultados y la validación cuantitativa: 15. Fase 1 – Investigación y Revisión (Objetivo Específico 1): Revisión bibliográfica exhaustiva de FER, CAA, PC, MediaPipe y clasificadores ligeros. Definición final de las 3 categorías emocionales a detectar (dolor, alegría, neutral) con justificación clínica basada en literatura. Selección de los datasets públicos a utilizar (RAF-DB, CK+) y definición de los criterios de evaluación. 16. Fase 2 – Datos y Pipeline de Extracción (Objetivos Específicos 2 y 3): Descarga y preprocesamiento del dataset público seleccionado. Implementación del pipeline MediaPipe Face Mesh para extracción automática de landmarks. Derivación del vector de características geométricas. Aplicación de técnicas de aumentación clásica documentada. Construcción del dataset final etiquetado. 17. Fase 3 – Entrenamiento y Evaluación Comparativa (Objetivo Específico 3): Entrenamiento de clasificadores SVM y MLP sobre vectores de landmarks. Fine-tuning de MobileNetV2 sobre imágenes faciales normalizadas. Evaluación comparativa mediante validación cruzada estratificada ($k=5$) con métricas de precisión, recall, F1-score

por clase y latencia de inferencia promedio sobre hardware objetivo. 18. Fase 4 – Optimización e Integración en Tiempo Real (Objetivo Específico 4): Integración del modelo de mejor desempeño en un pipeline de video en tiempo real utilizando OpenCV y MediaPipe. Medición de latencia end-to-end (captura → preprocesamiento → inferencia → salida). Optimización mediante exportación a formato ONNX si la latencia supera el umbral de 500ms. 19. Fase 5 – Interfaz CAA y Análisis de Viabilidad (Objetivos Específicos 5 y 6): Diseño e implementación de la GUI con PyQt5 o Tkinter. Implementación de síntesis de voz (gTTS o pyttsx3) y visualización de pictogramas. Módulo de personalización para cuidadores. Elaboración del análisis de viabilidad clínica y documentación de la hoja de ruta para extensión a datos reales de PC.

3.1.1.- Cronograma Detallado (6 Meses)

Fase Tarea Específica Duración (Semanas) Mes de Ejecución Fase 1: Investigación Revisión bibliográfica (FER, CAA, PC, landmarks) 3 Mes 1 Definición de categorías y selección de arquitectura base 1 Mes 1 Fase 2: Datos y Pipeline Descarga y preprocesamiento de dataset público (RAF-DB o CK+) 2 Mes 2 Implementación del pipeline MediaPipe para extracción de landmarks 3 Mes 2-3 Aumentación de datos clásica y etiquetado 2 Mes 3

final del dataset Fase 3: Modelo y Evaluación Entrenamiento y comparativa de clasificadores (SVM, MLP, MobileNetV2) 3 Mes 3-4 Evaluación rigurosa (precisión, recall, F1, latencia) 2 Mes 4-5 Fase 4: Interfaz y Validación Optimización de latencia e integración en tiempo real con OpenCV 2 Mes 5 Diseño e implementación de la GUI (CAA) 2 Mes 5-6 Análisis de viabilidad clínica y documentación final 1 Mes 6 Entrega Final Prototipo + documento de tesis - Fin Mes 6

3.1.2.- Diseño de la Investigación

Con base en la clasificación de Hernández, Fernández y Baptista (2014), el presente proyecto adopta un diseño no experimental de tipo comparativo-transversal. Se denomina no experimental porque la variable independiente — el tipo de pipeline FER — no es manipulada aleatoriamente entre sujetos; en cambio, los tres clasificadores (SVM, MLP y MobileNetV2) se evalúan sobre el mismo dataset y hardware, lo que constituye una comparativa sistemática sin asignación aleatoria de condiciones. Es transversal porque la recolección de métricas ocurre en un único período de evaluación (Trujillo Hernández, s.f.). Este diseño es el más apropiado dado que no es éticamente viable ni metodológicamente pertinente aleatorizar la asignación de arquitecturas computacionales a grupos de usuarios, y el objetivo central es comparar el desempeño de los clasificadores bajo condiciones idénticas de datos y hardware, no establecer una relación causa-efecto sobre una población de sujetos (Hernández et al., 2014). Tabla 1. Diseño de la investigación.

Elemento	Descripción	Alcance
Comparativo-transversal (no experimental)	Propósito	Comparar el desempeño de clasificadores ligeros (SVM, MLP, MobileNetV2) para FER en tiempo real sobre el mismo dataset público aumentado, como base de viabilidad técnica para una herramienta de CAA orientada a personas con Parálisis Cerebral.
Variable Independiente	Tipo de pipeline FER:	(a) clasificador sobre landmarks geométricos (SVM o MLP), versus (b) fine-tuning de MobileNetV2 sobre imagen facial normalizada.
Variables Dependientes		

Accuracy, Precision, Recall, F1-score por clase; latencia de inferencia (ms/fotograma); calidad del dataset aumentado. Instrumento / Técnica Validación cruzada estratificada k=5; medición de latencia sobre hardware objetivo; métricas de clasificación con Scikit-learn y TensorFlow/PyTorch.

Método / Diseño No experimental comparativo. Evaluación cuantitativa sobre dataset público (RAF-DB, CK+) con aumentación clásica documentada.

3.1.3.- Clasificación y Operacionalización de Variables

La correcta identificación de las variables y sus escalas de medición es fundamental para seleccionar las pruebas estadísticas adecuadas y garantizar la validez interna y externa de los resultados (Trujillo Hernández, s.f.). A continuación se presenta la operacionalización completa de las variables del estudio, clasificadas por su naturaleza, nivel de medición e interrelación. La Variable Independiente (VI) es el tipo de pipeline FER empleado: se trata de una variable cualitativa nominal dicotómica (pipeline basado en landmarks geométricos vs. pipeline basado en imagen normalizada con MobileNetV2). Al ser nominal, el análisis comparativo entre grupos se realiza mediante estadística no paramétrica cuando las variables dependientes no cumplen supuestos de normalidad, o mediante pruebas paramétricas (t de Student, ANOVA) cuando sí los cumplen (Trujillo Hernández, s.f.).

Tabla 2. Operacionalización de variables.

Variable	Tipo	Naturaleza	Escala de Medición	Unidad	Categorías	Estadística Apropia
Tipo de pipeline FER (VI)	Cualitativa nominal	Nominal (dicotómica)	Landmarks geométricos / Imagen normalizada	Porcentajes, chi cuadrada	Accuracy global (VD)	Cuantitativa continua Razón Proporción [0.0, 1.0] Media, DE, t de Student / ANOVA
Precision por clase (VD)	Cuantitativa continua	Razón Proporción [0.0, 1.0]	Media, DE, t de Student / ANOVA	Recall por clase (VD)	Cuantitativa continua Razón Proporción [0.0, 1.0]	Media, DE, t de Student / ANOVA
F1-score por clase (VD)	Cuantitativa continua	Razón Proporción [0.0, 1.0]	Media, DE, t de Student / ANOVA	Latencia de inferencia (VD)	Cuantitativa continua Razón	Milisegundos (ms) Media, DE, percentil 95
Categoría emocional detectada	Cualitativa nominal	Nominal (3 categorías)	Dolor / Alegría / Neutral	Porcentajes, chi cuadrada	Las variables dependientes métricas (Accuracy, Precision, Recall, F1-score y Latencia) son variables cuantitativas de razón — cuentan con cero absoluto y son determinadas mediante instrumentos objetivos (código de evaluación, cronómetro del sistema) — por lo que se analiza con estadística paramétrica: promedio, desviación estándar e intervalos	

de confianza al 95%. Para la comparativa entre los tres clasificadores se aplicará ANOVA de una vía con prueba post-hoc de Tukey si se cumplen los supuestos de normalidad (Shapiro-Wilk) y homocedasticidad (prueba de Levene); en caso contrario, se empleará la prueba no paramétrica de Kruskal-Wallis (Trujillo Hernández, s.f.). Respecto a la interrelación de variables, siguiendo la clasificación de Trujillo Hernández (s.f.), la relación es irreversible: el tipo de pipeline (VI) precede y determina las métricas de desempeño (VD), no a la inversa. Esto valida la dirección causal del análisis comparativo y la interpretación de los resultados en términos de qué arquitectura ofrece mejor viabilidad técnica para el sistema de CAA propuesto.

3.1.4.- Matriz de Congruencia

La matriz de congruencia integra los elementos centrales del diseño metodológico en una estructura que permite verificar la consistencia interna del proyecto: que la pregunta de investigación, las variables, la hipótesis, el objetivo general, los instrumentos y el método/diseño estén alineados entre sí

(Hernández et al., 2014). Tabla 3. Matriz de congruencia del proyecto de investigación. Pregunta de Investigación Variables (VI / VD) Hipótesis Objetivo General Instrumento / Técnica Método / Diseño ¿Es viable desarrollar un sistema FER operativo en tiempo real sobre hardware de consumo estándar, usando landmarks de MediaPipe y clasificadores ligeros entrenados con datasets públicos aumentados, como base para una herramienta de CAA para VI: Tipo de pipeline FER (landmarks vs. imagen normalizada MobileNetV2). VD: Accuracy, Recall, F1-score, latencia (ms). H1: El pipeline FER basado en landmarks + clasificador ligero alcanzará precisión >80% y latencia <500ms en hardware de consumo, demostrando viabilidad técnica como base de CAA para personas con PC. Desarrollar, entrenar y evaluar un prototipo funcional de FER en tiempo real basado en MediaPipe y clasificadores ligeros, que sirva como fundamento técnico y análisis de viabilidad para una herramienta de CAA orientada a personas con PC. Validación cruzada k=5; métricas de clasificación (Sklearn); medición de latencia sobre CPU i5; dataset RAF-DB/CK + con aumentación clásica documentada. No experimental, comparativo-transversal. Evaluación cuantitativa de razón con estadística paramétrica (ANOVA, t de Student) o no paramétrica (Kruskal-Wallis) según supuestos.

personas con PC?

3.2.- Requerimientos de Usuario

- Funcionalidad: El sistema debe detectar y clasificar correctamente al menos 3 estados emocionales (dolor, alegría, neutral) con una precisión superior al 80% (M3).
- Tiempo Real: La respuesta del sistema, desde la captura de la imagen hasta la traducción del mensaje, debe tener una latencia máxima de 500ms (M3).
- Usabilidad: La interfaz debe ser intuitiva, con elementos visuales claros, y permitir la personalización de mensajes de voz o pictogramas (M4), sin requerir conocimientos técnicos por parte del cuidador.
- Accesibilidad: El sistema debe operar en hardware de consumo común (laptop o PC de escritorio estándar) sin requerir GPU dedicada ni equipos especializados.
- No invasivo: La interacción debe realizarse exclusivamente mediante cámara web estándar, sin sensores adicionales ni contacto físico con la persona.
- Transparencia: El sistema debe mostrar opcionalmente el nivel de confianza de la predicción, permitiendo al cuidador evaluar la fiabilidad de la detección en tiempo real.

3.3.- Requerimientos del Sistema

Hardware: • Procesador: Mínimo Intel Core i5 de 8ª generación o equivalente AMD. • Memoria RAM: Mínimo 8 GB (16 GB recomendado para entrenamiento). • GPU: No requerida para inferencia. GPU opcional para acelerar el entrenamiento de MobileNetV2. • Cámara: Webcam USB estándar con resolución mínima de 720p a 30 FPS. Software y Tecnologías: • Lenguaje de Programación: Python 3.9 o superior. • Extracción de Landmarks: MediaPipe Face Mesh (Google). • Visión por Computadora: OpenCV 4.x. • Deep Learning: PyTorch o TensorFlow/Keras para fine-tuning de MobileNetV2. • Clasificadores Clásicos: Scikit-learn (SVM, MLP). • Interfaz Gráfica: PyQt5 o Tkinter. • Síntesis de Voz: gTTS o pyttsx3. • Sistema Operativo: Windows 10/11, Ubuntu 20.04+, o macOS 12+. Datos: • Dataset

base: RAF-DB (Real-world Affective Faces Database) o CK+ (Extended Cohn- Kanade Dataset), ambos de acceso público para investigación.

- El dataset aumentado final debe contener imágenes etiquetadas para las 3 categorías emocionales definidas.
- El modelo debe ser exportable a formato ONNX para optimización de latencia.

3.4.- Análisis de Riesgos y Plan de Contingencia

Se identifican cuatro riesgos principales con sus respectivos planes de mitigación: Riesgo 1: Fallo en la Meta de Precisión ($M3 < 80\%$) • Impacto: El sistema no sería suficientemente confiable para uso doméstico, comprometiendo la viabilidad del proyecto. • Mitigación: ◦ Transfer Learning con modelo pre-entrenado en ImageNet: utilizar pesos pre-entrenados de MobileNetV2 y aplicar fine-tuning solo en las últimas capas. ◦ Ensamble de modelos: combinar la predicción del clasificador sobre landmarks con la de MobileNetV2 mediante votación ponderada. ◦ Reducción de categorías: si las 3 categorías no son suficientemente discriminables, reducir a 2 (dolor vs. no-dolor) que es el estado más crítico clínicamente. Riesgo 2: Latencia Superior a 500ms ($M3$ incumplida) • Impacto: El sistema sería inútil para comunicación en tiempo real. • Mitigación: ◦ Exportar el modelo a formato ONNX y usar ONNX Runtime para inferencia optimizada en CPU. ◦ Reducir la resolución de entrada al modelo (96×96 o 64×64 px) sin pérdida significativa de precisión. ◦ Pivotar al clasificador SVM sobre landmarks, cuya latencia de inferencia es inferior a 5ms en cualquier hardware. Riesgo 3: Generalización Insuficiente a Expresiones Atípicas • Impacto: El modelo entrenado con datos estándar puede fallar ante las expresiones atípicas características de personas con PC. • Mitigación: ◦ Este riesgo es intrínseco al enfoque y se documenta explícitamente como limitación en el análisis de viabilidad ($M5$). ◦ Se aplicarán técnicas de aumentación que simulen variaciones atípicas: deformaciones geométricas controladas de landmarks, oclusión parcial de regiones faciales. ◦ El análisis de viabilidad establecerá los criterios mínimos del dataset clínico necesario para superar esta limitación. Riesgo 4: Consideraciones Éticas y Privacidad • Impacto: El manejo inadecuado de datos faciales puede resultar en violaciones de privacidad. • Mitigación:

- En esta fase se utilizan exclusivamente datasets públicos de investigación sin datos de menores con PC.
- El sistema procesa las imágenes localmente en el dispositivo del usuario; no se transmiten datos faciales a servidores externos.
- El protocolo de consentimiento informado para la eventual fase de validación clínica se documentará como parte de la hoja de ruta ($M5$), siguiendo las directrices de van der Veen et al. (2022).

UNIDAD IV.- DISEÑO DEL SISTEMA

4.1.- Diseño del Sistema

El sistema se concibe como una arquitectura modular de tres componentes principales, diseñada para maximizar la eficiencia computacional y la mantenibilidad del código: 1. Módulo de Captura y

Preprocesamiento • Función: Captura el stream de video de la cámara web y prepara los datos faciales para el análisis. • Proceso: Detección de rostro mediante el detector integrado de MediaPipe. Extracción de 478 landmarks tridimensionales con MediaPipe Face Mesh. Derivación del vector de características geométricas (distancias euclidianas entre puntos clave: comisuras labiales, cejas, párpados, punta nasal). Normalización de la imagen facial recortada para entrada al modelo convolucional (cuando aplica). 2. Módulo de Reconocimiento de Expresiones Faciales (FER) • Función: Clasificación de la expresión facial en las categorías definidas. • Enfoque A – Clasificador sobre landmarks: Vector de distancias geométricas → SVM o MLP pre-entrenado → vector de probabilidades por clase. Latencia estimada < 10ms. • Enfoque B – MobileNetV2 con fine-tuning: Imagen facial normalizada (96×96 px) → MobileNetV2 adaptado → vector de probabilidades por clase. Latencia estimada < 200ms sobre CPU i5. • Salida: Probabilidad para cada una de las 3 categorías emocionales definidas, con umbral de confianza configurable. 3. Módulo de Interfaz de Usuario y Traducción (CAA) • Función: Recibe la clasificación de emoción y la traduce a un mensaje comprensible para la persona y el cuidador. • Traducción: La expresión clasificada activa un mensaje de voz sintetizado (gTTS/pyttsx3) o un pictograma visual. Ejemplo: detección de "Dolor" → reproducción de "Necesito ayuda, me duele" + pictograma de dolor. • Personalización: Base de datos local (SQLite) que permite al cuidador asociar expresiones específicas con frases o pictogramas personalizados para la persona. • Transparencia: Visualización opcional del nivel de confianza de la predicción, permitiendo al cuidador evaluar cuándo el sistema está operando con certeza suficiente. Diagrama de Flujo del Sistema [Cámara Web (Input)] ↓ { Módulo de Captura y Preprocesamiento }

Detección de rostro → Extracción de 478 landmarks → Vector geométrico ↓ { Módulo FER (Clasificador Ligero) } SVM/MLP sobre landmarks | MobileNetV2 fine-tuned ↓ { Módulo de Interfaz y Traducción (CAA) } Mensaje de voz + Pictograma personalizable ↓ [Audio / Pantalla (Output)]

UNIDAD V.- IMPLEMENTACIÓN Y EVALUACIÓN DEL SISTEMA

5.1.- Implementación del Pipeline de Extracción de Landmarks

La implementación del pipeline de extracción de características faciales constituye el núcleo técnico del proyecto y el punto de partida para todas las etapas posteriores. El pipeline se estructura en tres subprocesos secuenciales ejecutados fotograma a fotograma sobre el flujo de video capturado por la cámara web.

5.1.1.- Captura y Preprocesamiento de Video

La captura de video se realiza mediante OpenCV (cv2.VideoCapture), configurada para operar a una resolución de 640×480 píxeles y una tasa de 30 fotogramas por segundo. Cada fotograma se convierte del espacio de color BGR (nativo de OpenCV) al espacio RGB requerido por MediaPipe antes de ser procesado. Adicionalmente, se aplica una normalización de histograma adaptativa (CLAHE) sobre el canal de luminancia para mejorar la robustez ante condiciones de iluminación variable, que es un factor

crítico en entornos domésticos y escolares donde el sistema será eventualmente utilizado. El preprocesamiento incluye también una etapa de detección de rostro mediante el detector de cara integrado en MediaPipe, que emplea un modelo basado en Single Shot Detector (SSD) capaz de operar a más de 60 FPS sobre CPU. Una vez detectado el rostro, la región de interés (ROI) se recorta y redimensiona a 96×96 píxeles para su uso en el modelo convolucional MobileNetV2, mientras que los 478 landmarks tridimensionales se extraen directamente de la imagen completa para el clasificador geométrico.

5.1.2.- Extracción de Características Geométricas

A partir de los 478 landmarks en coordenadas (x, y, z) normalizadas proporcionados por MediaPipe Face Mesh, se deriva un vector de características geométricas que codifica

la expresión facial de manera compacta. La selección de los puntos clave se basa en la anatomía facial funcional: se priorizan las regiones con mayor variabilidad expresiva — comisuras labiales (landmarks 61, 291), comisuras oculares (landmarks 33, 133, 263, 362), cejas (landmarks 70, 63, 105, 300, 293, 334), párpados superiores e inferiores, y el puente nasal. El vector de características final combina tres tipos de medidas: (1) distancias euclidianas entre pares de puntos clave, normalizadas respecto a la distancia interpupilar para garantizar invarianza a la escala y distancia a la cámara; (2) ratios de aspecto para las regiones oculares (Eye Aspect Ratio, EAR) y oral (Mouth Aspect Ratio, MAR), que cuantifican el grado de apertura; y (3) ángulos de inclinación de las cejas respecto al eje horizontal. El vector resultante tiene una dimensionalidad de 68 características, lo que lo hace extremadamente manejable para clasificadores clásicos como SVM y MLP.

5.1.3.- Validación del Pipeline de Extracción

Para validar la correctitud y estabilidad del pipeline de extracción, se diseña un protocolo de prueba con video de referencia donde un sujeto adulto sin condición neurológica ejecuta secuencias de las tres expresiones objetivo (dolor, alegría, neutral) durante 30 segundos cada una. Las métricas de validación del pipeline son: tasa de detección de rostro (porcentaje de fotogramas donde MediaPipe detecta exitosamente los 478 landmarks), estabilidad temporal del vector de características (varianza del vector en expresión neutral sostenida), y latencia de extracción por fotograma (tiempo desde la captura hasta la generación del vector). Se considera exitoso un pipeline que opere a ≥ 25 FPS con tasa de detección superior al 95% bajo condiciones de iluminación estándar de interior.

5.2.- Construcción y Augmentación del Dataset de Entrenamiento

La calidad y representatividad del dataset de entrenamiento es determinante para el desempeño del clasificador. Esta sección detalla el proceso de selección, filtrado, extracción de características y augmentación aplicado a los datasets públicos RAF-DB y CK+.

5.2.1.- Descripción de los Datasets Base

El Real-world Affective Faces Database (RAF-DB) es un dataset de gran escala con más de 29,672 imágenes faciales etiquetadas con 7 expresiones básicas, recopiladas en condiciones no controladas (iluminación variable, poses diversas, oclusiones parciales). Para este proyecto se seleccionan las categorías de Felicidad (mapeada a “Alegría”) y Neutral, extrayendo las imágenes correspondientes del conjunto de entrenamiento oficial. El Extended Cohn-Kanade Dataset (CK+) es un dataset de laboratorio con 327 secuencias de expresiones de 118 sujetos, capturadas en condiciones controladas. Su relevancia para este proyecto radica en la presencia de la categoría “Disgust” y “Fear”, que en combinación se utilizan como proxy para la categoría “Dolor” en ausencia de un dataset específico para esta expresión. Esta decisión metodológica se documenta explícitamente como una limitación del sistema, dado que el dolor en PC puede presentar patrones faciales distintos a los del malestar o miedo en población neurotípica.

5.2.2.- Pipeline de Augmentación Clásica

La augmentación de datos se implementa con el objetivo de incrementar la diversidad del conjunto de entrenamiento y reducir el sobreajuste. Se aplican las siguientes transformaciones de manera aleatoria y combinada durante el entrenamiento, con las siguientes probabilidades de aplicación: ● Rotación aleatoria: $\pm 15^\circ$ sobre el eje z, $p=0.5$. Simula variaciones en la inclinación de la cabeza de la persona respecto a la cámara. ● Volteo horizontal (flip): $p=0.5$. Incrementa la diversidad sin alterar la expresión, dado que las expresiones faciales son aproximadamente simétricas. ● Ajuste de brillo y contraste: factor de brillo en $[0.7, 1.3]$, contraste en $[0.8, 1.2]$, $p=0.4$. Simula condiciones de iluminación variable de interior. ● Recorte aleatorio (random crop): recorte de hasta el 10% de los bordes, seguido de redimensionado a la resolución objetivo, $p=0.3$. Simula variaciones en la posición del rostro en el encuadre. ● Adición de ruido gaussiano: desviación estándar σ $[0, 0.05]$ sobre la imagen $\in$ normalizada, $p=0.2$. Simula imperfecciones del sensor de la cámara web. ● Desenfoque gaussiano (Gaussian blur): kernel de 3×3 px, $p=0.15$. Simula movimientos involuntarios de la persona o baja calidad de la cámara. Cada imagen del dataset base genera 5 versiones augmentadas, resultando en un factor de expansión 6x sobre el conjunto original. El dataset final balanceado contiene al menos 2,000 imágenes por categoría emocional, garantizando que el clasificador no esté sesgado hacia ninguna clase en particular.

5.3.- Entrenamiento y Comparativa de Clasificadores

Esta sección describe el proceso de entrenamiento de cada clasificador evaluado y el protocolo de evaluación comparativa diseñado para identificar el modelo de mejor desempeño para su integración en el sistema en tiempo real.

5.3.1.- Clasificador SVM sobre Landmarks Geométricos

El clasificador SVM (Support Vector Machine) opera sobre el vector de 68 características geométricas descrito en la Sección 5.1.2. Se utiliza la implementación de Scikit-learn (`sklearn.svm.SVC`) con kernel de función de base radial (RBF), cuya capacidad de separación no lineal es adecuada para las distribuciones de los vectores de características faciales. Los hiperparámetros C (regularización) y γ (parámetro del kernel RBF) se optimizan mediante búsqueda en cuadrícula (`GridSearchCV`) con validación cruzada estratificada de 5 pliegues ($k=5$), explorando $C \in \{0.1, 1, 10, 100\}$ y $\gamma \in \{'scale', \in \{0.001, 0.01, 0.1\}\}$. El entrenamiento del SVM es computacionalmente ligero: con un dataset de 6,000 muestras de 68 características, el tiempo de entrenamiento estimado es inferior a 5 minutos sobre CPU. La inferencia del SVM es extremadamente rápida ($< 1\text{ms}$ por muestra), lo que garantiza que no introduce latencia significativa en el pipeline de tiempo real. Las probabilidades de clase se obtienen mediante calibración de Platt

(`probability=True` en `SVC`), necesaria para el módulo de transparencia de la interfaz CAA.

5.3.2.- Clasificador MLP sobre Landmarks Geométricos

Como alternativa al SVM, se evalúa un Perceptrón Multicapa (MLP) de arquitectura shallow: una capa de entrada de 68 neuronas, dos capas ocultas de 256 y 128 neuronas respectivamente con activación ReLU, dropout del 30% entre capas ocultas para regularización, y una capa de salida de 3 neuronas con activación Softmax. El entrenamiento se realiza con el optimizador Adam ($\text{lr}=0.001$) durante 100 épocas con reducción de tasa de aprendizaje en plateau (`ReduceLROnPlateau`, $\text{factor}=0.5$, $\text{patience}=10$). Se utiliza early stopping con $\text{patience}=15$ épocas para prevenir el sobreajuste.

5.3.3.- Fine-Tuning de MobileNetV2

MobileNetV2 se carga con pesos preentrenados en ImageNet (transfer learning). La estrategia de fine-tuning es progresiva: en una primera fase se congela toda la red base y se entrena únicamente la cabeza clasificadora (Global Average Pooling $\rightarrow$ Dense(128, ReLU) $\rightarrow$ Dropout(0.3) $\rightarrow$ Dense(3, Softmax)) durante 20 épocas con $\text{lr}=0.001$. En una segunda fase, se descongela el bloque superior de MobileNetV2 (a partir de la capa “block_14”) y se continúa el entrenamiento con $\text{lr}=0.0001$ durante 30 épocas adicionales. Esta estrategia previene la destrucción de las características preaprendidas en las capas inferiores de la red, que son altamente transferibles a la tarea de reconocimiento facial. La imagen de entrada se redimensiona a $96 \times 96 \times 3$ píxeles y se normaliza al rango $[0, 1]$. El entrenamiento se realiza con Data Augmentation en línea (Keras ImageDataGenerator o `torchvision.transforms`) sobre los mismos parámetros descritos en la Sección 5.2.2. El tamaño de lote (batch size) se establece en 32 muestras, adecuado para entrenamiento en CPU con restricciones de memoria RAM de 8 GB.

5.3.4.- Protocolo de Evaluación Comparativa

Los tres clasificadores (SVM, MLP y MobileNetV2) se evalúan bajo condiciones idénticas para garantizar la comparabilidad de los resultados. El dataset total se divide en conjuntos de entrenamiento (70%), validación (15%) y prueba (15%), utilizando estratificación por clase para mantener la distribución balanceada en todos los subconjuntos. La partición de prueba nunca es vista durante el entrenamiento ni la selección de hiperparámetros. Las métricas de evaluación registradas para cada clasificador son: Accuracy global (porcentaje de predicciones correctas sobre el conjunto de prueba), Precision, Recall y F1-score por clase (con énfasis especial en la clase “Dolor” por ser la más crítica clínicamente), Matriz de Confusión completa, y Latencia de inferencia promedio por fotograma medida en el hardware objetivo (laptop con CPU Intel Core i5 de 8ª generación, sin GPU dedicada) sobre 500 fotogramas de video en tiempo real.

5.4.- Integración en Pipeline de Tiempo Real

Una vez identificado el clasificador de mejor desempeño en la evaluación comparativa, se procede a su integración en el pipeline de inferencia en tiempo real. El pipeline

completo, desde la captura del fotograma hasta la generación de la salida de la interfaz CAA, opera en un bucle principal de procesamiento implementado en Python con threading para separar la captura de video, la inferencia del modelo y la actualización de la interfaz gráfica.

5.4.1.- Arquitectura del Bucle Principal

El bucle principal de procesamiento opera con la siguiente secuencia por fotograma: (1) Captura del fotograma mediante OpenCV (`cv2.VideoCapture.read()`); (2) Conversión BGR→RGB y aplicación de CLAHE para normalización de iluminación; (3) Procesamiento de MediaPipe Face Mesh para detección de landmarks; (4) Derivación del vector de características geométricas (si se usa SVM/MLP) o recorte y normalización de la ROI facial (si se usa MobileNetV2); (5) Inferencia del clasificador y obtención de probabilidades por clase; (6) Aplicación de suavizado temporal mediante filtro de media móvil sobre los últimos 5 fotogramas para evitar fluctuaciones en la clasificación; (7) Actualización de la interfaz gráfica si la emoción clasificada supera el umbral de confianza configurable (por defecto: 0.65).

5.4.2.- Optimización de Latencia con ONNX Runtime

En caso de que el modelo MobileNetV2 supere el umbral de latencia de 500ms en el hardware objetivo, se procede a la exportación del modelo entrenado al formato ONNX (Open Neural Network Exchange) y su ejecución mediante ONNX Runtime, que aplica optimizaciones específicas para la arquitectura del CPU objetivo. Estudios de referencia reportan reducciones de latencia del 30-50% al migrar desde TensorFlow/PyTorch nativo a ONNX Runtime en inferencia CPU. Adicionalmente, se evalúa la cuantización de pesos del modelo (INT8) mediante las herramientas de ONNX Runtime Quantization, que permite reducir la huella de memoria del modelo en un factor de 4x con pérdida de precisión generalmente inferior al 1%.

5.4.3.- Medición de Latencia End-to-End

La latencia total del sistema (end-to-end) se mide como el tiempo transcurrido desde la captura del fotograma (timestamp de `cv2.VideoCapture.read()`) hasta la actualización de la interfaz gráfica con la nueva clasificación. Se registra la latencia de cada etapa individualmente para identificar cuellos de botella: latencia de captura y preprocesamiento, latencia de MediaPipe (extracción de landmarks), latencia de inferencia del clasificador, y latencia de actualización de la GUI. Las mediciones se realizan sobre 1,000 fotogramas consecutivos y se reportan como mediana y percentil 95 para capturar tanto el comportamiento típico como los casos de latencia pico que podrían degradar la experiencia del usuario.

5.5.- Diseño de la Interfaz de Usuario (CAA)

La interfaz gráfica de usuario (GUI) representa el componente de mayor impacto para el usuario final: el cuidador y la persona con PC. Su diseño sigue principios de diseño centrado en el usuario con especial atención a la usabilidad en contextos de alta carga cognitiva y emocional.

5.5.1.- Principios de Diseño de la Interfaz

- **Simplicidad visual:** la interfaz presenta únicamente la información esencial — el pictograma o mensaje activo, el nivel de confianza de la detección y la vista de la cámara. Se evita la sobrecarga de información que podría confundir al cuidador en momentos críticos.
- **Contraste y tamaño de elementos:** siguiendo las guías de accesibilidad WCAG 2.1, todos los elementos visuales mantienen un contraste mínimo de 4.5:1 y los pictogramas tienen un tamaño mínimo de 200×200 px para facilitar su reconocimiento a distancia.
- **Retroalimentación clara:** cuando el sistema detecta una emoción con confianza suficiente, la interfaz muestra una transición visual destacada y reproduce el mensaje de voz automáticamente, sin requerir interacción del cuidador.
- **Personalización accesible:** el módulo de personalización permite al cuidador asociar expresiones con mensajes o pictogramas mediante una interfaz de configuración de tres pasos, sin requerir conocimientos técnicos.

5.5.2.- Módulo de Síntesis de Voz y Pictogramas

La traducción de expresiones a mensajes comprensibles se implementa mediante dos canales de salida complementarios. El canal auditivo utiliza la librería gTTS (Google Text- to-Speech) para síntesis de voz en español con latencia de generación inferior a 200ms en conexión a internet, o pyttsx3 como alternativa offline que opera directamente sobre el motor de síntesis del sistema operativo. El canal visual muestra pictogramas de la biblioteca ARASAAC (Augmentative and Alternative Communication Symbols), que son de uso gratuito para fines no comerciales y educativos, y cuentan con validación en el contexto hispanohablante de CAA (Sennott et al., 2019), y cuentan con amplia familiaridad en el contexto de CAA en habla hispana. La base de datos local de personalización se implementa con SQLite (sin servidor, archivo local) y almacena pares (expresión_detectada, mensaje_personalizado, ruta_pictograma, habilitado). Esto permite que el cuidador ajuste los mensajes a las necesidades específicas de la persona — por ejemplo, asociar “Alegría” con el nombre favorito de la persona o una frase familiar que resulte más significativa que un mensaje genérico.

5.5.3.- Módulo de Transparencia y Confianza

Un componente diferencial de la interfaz es el indicador de confianza de la predicción, visible opcionalmente en la parte inferior de la pantalla. Este indicador muestra una barra de progreso coloreada (verde > 80%, amarillo 65-80%, rojo < 65%) que representa la probabilidad asignada a la emoción clasificada. Cuando la confianza cae por debajo del umbral configurable, el sistema entra en modo de espera y no emite ningún mensaje, evitando falsos positivos que podrían generar confusión o desconfianza del cuidador en el sistema. Este diseño es consistente con las recomendaciones de van der Veen et al. (2022) sobre transparencia en sistemas de IA aplicados a rehabilitación infantil.

5.6.- Resultados Esperados y Criterios de Éxito

Esta sección establece los resultados cuantitativos y cualitativos esperados al concluir la fase de implementación y evaluación, así como los criterios de éxito que determinan la viabilidad técnica del sistema propuesto.

5.6.1.- Resultados Esperados en Clasificación

Basándose en la literatura de referencia y las características del dataset de entrenamiento propuesto, se anticipan los siguientes rangos de desempeño para cada clasificador sobre el conjunto de prueba (no visto durante el entrenamiento):

- SVM sobre landmarks geométricos: Accuracy esperada del 78-85%. Su fortaleza radica en la robustez ante variaciones de pose e iluminación gracias a la normalización intrínseca del vector de landmarks. Su limitación principal es la menor capacidad de discriminar microexpresiones sutiles en comparación con los modelos convolucionales.
- MLP sobre landmarks geométricos: Accuracy esperada del 80-87%. La mayor capacidad de representación no lineal del MLP respecto al SVM puede capturar interacciones más complejas entre características geométricas, potencialmente mejorando la discriminación de la categoría “Dolor”.
- MobileNetV2 con fine-tuning: Accuracy esperada del 85-92%. Al operar sobre la imagen facial completa, puede capturar características texturales y de coloración que no están disponibles en el vector de landmarks geométricos, lo que constituye su ventaja principal ante los clasificadores de baja dimensionalidad. En todos los casos, se presta especial atención al Recall de la clase “Dolor”, cuya minimización de falsos negativos es clínicamente prioritaria: un sistema que falla en detectar dolor en una persona con PC tiene consecuencias directas sobre su bienestar. Se establece un umbral mínimo de Recall del 75% para esta clase como criterio adicional de viabilidad del sistema.

5.6.2.- Resultados Esperados en Latencia

Las latencias de inferencia esperadas para cada componente del pipeline, medidas sobre hardware objetivo (Intel Core i5, 8 GB RAM, sin GPU), son las siguientes: captura y preprocesamiento de fotograma (10-20ms), MediaPipe Face Mesh extracción de landmarks (15-30ms), derivación del vector geométrico (< 2ms), inferencia SVM/MLP (< 5ms), inferencia MobileNetV2 nativo (80-180ms), inferencia MobileNetV2 con ONNX Runtime (50-120ms), suavizado temporal y actualización de GUI (5-10ms). La latencia end-to-end total para el clasificador SVM sobre landmarks se estima en 30-60ms, mientras que para MobileNetV2 con ONNX Runtime se estima en 80-240ms, ambos por debajo del umbral de 500ms establecido como criterio de éxito en M3.

5.6.3.- Análisis de Viabilidad Clínica Preliminar

El análisis de viabilidad clínica (Meta M5) constituye una de las aportaciones más relevantes del proyecto para la comunidad científica. Este documento sintetiza las brechas identificadas entre el sistema desarrollado y un sistema de CAA clínicamente validado para uso con personas con PC, y propone una hoja de ruta metodológica para superarlas. Las brechas identificadas a priori incluyen: (1) la ausencia de datos de entrenamiento de personas con PC, que presentan expresiones faciales con patrones biomecánicos diferentes a los de la población neurotípica, variando además según la edad y el tipo de PC utilizada en los datasets públicos RAF-DB y CK+; (2) la variabilidad intraindividual significativa en PC, donde el mismo niño puede expresar la misma emoción de maneras distintas en función de su nivel de espasticidad y fatiga; (3) la ausencia de validación con usuarios finales (cuidadores y personas con PC) que podría revelar necesidades de usabilidad no anticipadas en el diseño inicial; y (4) las

consideraciones éticas y legales del tratamiento de datos biométricos de menores con condición neurológica, que requieren protocolos de consentimiento informado específicos según las directrices de van der Veen et al. (2022). La hoja de ruta propuesta para superar estas brechas en investigación futura incluye tres fases: una primera fase de recopilación de datos clínicos con un mínimo de 30 personas con PC y al menos 3 sesiones de grabación por sujeto (estimando > 5,000 fotogramas etiquetados por clase); una segunda fase de re-entrenamiento del pipeline con los datos clínicos utilizando el modelo del presente proyecto como punto de partida (transfer learning intradominio); y una tercera fase de validación ecológica en entornos reales (hogar y aula) con métricas de usabilidad (SUS, escala de usabilidad del sistema) y satisfacción del cuidador.

UNIDAD VI.- DISCUSIÓN

6.1.- Interpretación del Enfoque Metodológico

La decisión de adoptar un enfoque basado en landmarks geométricos como representación intermedia, en lugar de operar directamente sobre la imagen bruta, responde a consideraciones tanto técnicas como clínicas. Desde el punto de vista técnico, el vector de características geométricas normalizado proporciona invarianza intrínseca a la escala (distancia sujeto-cámara), la iluminación (los landmarks son posiciones, no intensidades de píxel) y las variaciones de tono de piel, que son fuentes de sesgo conocidas en los clasificadores CNN entrenados con datasets de distribución no representativa. Desde el punto de vista clínico, la interpretabilidad del vector de características geométricas es un activo diferencial: cada componente del vector (ej. Eye Aspect Ratio, Mouth Aspect Ratio) corresponde a una medida anatómica con significado clínico establecido, lo que facilita la explicación del comportamiento del sistema a los profesionales de la salud involucrados en la eventual validación clínica. Esta interpretabilidad es especialmente valiosa en el contexto de IA médica, donde la opacidad de los modelos de caja negra es una barrera reconocida para la adopción clínica (van der Veen et al., 2022) (van der Veen et al., 2022).

6.2.- Limitaciones del Estudio y Consideraciones de Generalización

La limitación más significativa de esta investigación es la ausencia de datos de entrenamiento y validación de personas reales con Parálisis Cerebral. El uso de datasets públicos de población neurotípica (RAF-DB, CK+) como proxy introduce un sesgo de distribución de dominio cuya magnitud real solo puede cuantificarse cuando el sistema se evalúe sobre datos clínicos. Este sesgo es especialmente pronunciado para la categoría de Dolor, que en el dataset de entrenamiento se aproxima mediante las expresiones de Disgusto y Miedo, las cuales comparten solo parcialmente la activación muscular facial del dolor real (Unidades de Acción FACS 4, 6, 7, 9, 10, 25, 26, 43 según el PSPI Pain Score (Sabater-Gárriz et al., 2024)). Una segunda limitación estructural es la variabilidad intraindividual en PC. A diferencia de los sujetos neurotípicos donde la misma emoción produce patrones musculares relativamente consistentes entre individuos (universalidad de las expresiones básicas, Ekman 1992), en PC la expresión facial está

modulada por el patrón específico de lesión cerebral de cada persona, resultando en alta variabilidad interpersonal e incluso intrapersonal (Kristoffersson et al., 2020), dependiendo del nivel de fatiga, medicación y estado general de la persona. Esto implica que un sistema de CAA basado en FER para uso real con una persona específica necesitará probablemente un proceso de calibración personalizada, donde el cuidador valide y corrija las predicciones del sistema durante un periodo de adaptación. La tercera limitación es la restricción del sistema a tres categorías emocionales (dolor, alegría, neutral), que cubre solo una fracción de las necesidades comunicativas de una persona con PC. Estados como el aburrimiento, la incomodidad postural, el hambre o el sueño son frecuentes y clínicamente relevantes, pero su expresión facial en PC puede

ser extremadamente sutil o idiosincrática, haciendo su detección automatizada un problema abierto que requiere investigación futura específica.

6.3.- Comparativa con Trabajos Relacionados

El trabajo de Sabater-Gárriz et al. (2024) es el más directamente comparable al presente proyecto, dado que aborda específicamente el reconocimiento facial automatizado en adultos con PC para evaluación del dolor. Su sistema emplea una arquitectura CNN profunda (ResNet-50) y un dataset propio de 22 sujetos adultos con PC, alcanzando un AUC de 0.78 para la detección binaria de dolor/no-dolor. La principal diferencia metodológica con el presente trabajo es la disponibilidad de datos clínicos reales, que el presente proyecto no puede replicar en su fase actual, pero que identifica como el paso siguiente necesario en la hoja de ruta. Bi et al. (2025) realizaron la comparativa más reciente entre arquitecturas CNN para FER en tiempo real, incluyendo MobileNetV2, VGG-16, ResNet y Swin Transformer. Su conclusión de que MobileNetV2 ofrece el mejor equilibrio precisión/eficiencia en hardware de consumo respalda directamente la selección arquitectónica de este proyecto. Sin embargo, su evaluación se realizó sobre datasets de población neurotípica en condiciones de laboratorio, por lo que sus métricas de referencia no son directamente extrapolables al dominio de PC. Gaya-Morey et al. (2024) evaluaron FER en personas con discapacidad intelectual, un dominio adyacente al de PC que comparte la característica de expresiones faciales atípicas respecto a los datasets estándar. Su análisis estadístico demostró que las distribuciones de activaciones musculares en discapacidad intelectual difieren significativamente de las distribuciones de los datasets de referencia, reduciendo la precisión de los clasificadores preentrenados en un 12-18% respecto a los reportados en los trabajos originales (Gaya-Morey et al., 2024). Este hallazgo anticipa que el presente sistema enfrentará una degradación similar cuando se evalúe con datos reales de personas con PC, y refuerza la importancia del análisis de viabilidad como aportación central del trabajo.

6.4.- Implicaciones Éticas y Consideraciones de Privacidad

El desarrollo de sistemas de inteligencia artificial para su uso con poblaciones vulnerables, y en particular con menores con condición neurológica, requiere una reflexión ética sistemática que va más allá del cumplimiento normativo. Van der Veen et al. (2022) identifican cinco principios éticos

específicos para el uso de inteligencia artificial en rehabilitación infantil: beneficencia (el sistema debe mejorar el bienestar de la persona), no maleficencia (el sistema no debe causar daño, incluyendo daño psicológico por errores de clasificación), autonomía (el sistema debe potenciar la capacidad expresiva de la persona, no sustituirla), justicia (el sistema debe ser accesible equitativamente, no solo para quienes pueden pagarlo) y transparencia (el funcionamiento del sistema debe ser comprensible para los cuidadores y profesionales). En el ámbito de la privacidad, el sistema procesa datos biométricos especialmente sensibles: imágenes faciales de menores con condición médica. En el contexto de la

legislación mexicana, la Ley Federal de Protección de Datos Personales en Posesión de los Particulares (LFPDPPP) y su reglamento establecen requisitos específicos para el tratamiento de datos biométricos de menores, incluyendo el consentimiento informado de los tutores legales y la obligación de implementar medidas de seguridad técnicas y organizativas adecuadas. El diseño del sistema en su fase actual mitiga estos riesgos al procesar las imágenes exclusivamente de forma local en el dispositivo del usuario, sin transmisión a servidores externos, y al utilizar únicamente datasets públicos de investigación sin datos de menores con PC.

6.5.- Trabajo Futuro y Extensiones del Sistema

El presente proyecto establece una base metodológica sólida sobre la cual pueden construirse múltiples líneas de investigación futura de mayor alcance e impacto clínico. Las extensiones más relevantes identificadas son:

- **Recopilación de dataset clínico propio:** La extensión más crítica y prioritaria es la recopilación de un dataset de expresiones faciales de personas con PC en colaboración con instituciones clínicas. Un protocolo de 30 sesiones con 15-20 participantes, con videograbación durante actividades cotidianas y etiquetado por terapeutas especializados, generaría el volumen mínimo de datos para el re-entrenamiento del pipeline con datos representativos del dominio objetivo.
- **Personalización adaptativa:** La integración de un módulo de aprendizaje continuo que permita al sistema ajustar sus parámetros de clasificación basándose en el feedback del cuidador durante el uso real, implementando técnicas de few-shot learning o fine-tuning incremental sobre los patrones idiosincráticos de cada persona específica.
- **Multimodalidad:** La incorporación de señales complementarias a la expresión facial, como la vocalización no verbal (detección de llanto, risas, quejidos mediante análisis de audio), podría incrementar significativamente la robustez del sistema ante oclusiones faciales o condiciones de iluminación adversas. La fusión de modalidades (video + audio) a nivel de probabilidades de clase es una extensión arquitectónicamente directa del sistema propuesto.
- **Despliegue en dispositivos móviles:** La portabilidad del sistema a plataformas Android e iOS, aprovechando la disponibilidad de MediaPipe para ambas plataformas y las capacidades de inferencia en dispositivos móviles modernos (Neural Engine en Apple, NPU en Qualcomm), permitiría el uso del sistema en entornos escolares y de terapia sin dependencia de un ordenador de escritorio.
- **Evaluación de usabilidad con usuarios finales:** La realización de un estudio de usabilidad con cuidadores reales de personas con PC, aplicando la Escala de Usabilidad del Sistema —System Usability Scale,

SUS— y entrevistas semiestructuradas (van der Veen et al., 2022), proporcionaría retroalimentación valiosa para iterar sobre el diseño de la interfaz y los criterios de activación de mensajes.

UNIDAD VII.- DESARROLLO E IMPLEMENTACION

7.1.- Arquitectura del Sistema Desarrollado

El desarrollo del sistema se estructura en tres módulos de software independientes pero interoperables, diseñados siguiendo el principio de separación de responsabilidades. Esta arquitectura modular permite sustituir o mejorar cada componente de forma independiente sin modificar el resto del sistema, en consonancia con el diseño escalable propuesto en la Unidad IV. El Módulo 1 (`extractor.py`) se encarga del procesamiento por lotes del dataset: recorre las carpetas de imágenes etiquetadas, aplica MediaPipe Frame por Frame y extrae el vector de 68 características geométricas de cada rostro, almacenando el resultado en un archivo CSV listo para entrenamiento. El Módulo 2 (`clasificador.py`) carga ese CSV, entrena un clasificador SVM con kernel RBF mediante validación cruzada estratificada $k=5$, reporta las métricas de evaluación y serializa el modelo entrenado en formato `.pkl`. El Módulo 3 (`interfaz.py`) integra el pipeline completo en una interfaz gráfica PyQt5 orientada al cuidador: muestra la emoción detectada con pictograma, color diferenciado y síntesis de voz, operando en tiempo real sin requerir GPU dedicada.

7.2.- Módulo 1: Extracción de Características (`extractor.py`)

El script `extractor.py` implementa el pipeline de extracción de características descrito en la sección 5.1.2. Para cada imagen del dataset, el módulo aplica MediaPipe FaceLandmarker en modo IMAGE (inferencia por fotograma estático), extrae los 478 landmarks tridimensionales y deriva el vector de 68 características geométricas normalizadas respecto a la distancia intercantal. Las características incluyen EAR (Eye Aspect Ratio), MAR (Mouth Aspect Ratio), distancias euclidianas normalizadas entre regiones clave, ratios de apertura y métricas de asimetría facial.

7.2.1.- Ejecución

`python extractor.py --dataset ./dataset --output features.csv` El dataset debe organizarse con una subcarpeta por categoría emocional (`alegria/`, `dolor/`, `neutral/`) conteniendo las imágenes en formato JPG o PNG. El resultado es un archivo `features.csv` con 68 columnas de características más una columna de etiqueta, listo para ser consumido por el módulo de entrenamiento.

7.2.2.- Evidencia de ejecución

La extracción de características geométricas opera sobre cada imagen del dataset procesándola con MediaPipe FaceLandmarker en modo estático (`RunningMode.IMAGE`). Para cada rostro detectado se derivan 68 características normalizadas respecto a la distancia intercantal, incluyendo EAR, MAR, distancias euclidianas entre regiones clave y métricas de asimetría facial. El resultado se almacena en un archivo CSV con una fila por imagen y una columna de etiqueta de clase.

Figura 2. Pipeline FER — expresión neutral con sonrisa leve. Clasificación correcta NEUTRAL. FPS: 29.9.

7.3.- Modulo 2: Entrenamiento y Evaluacion (clasificador.py)

El script clasificador.py implementa el protocolo de evaluacion comparativa descrito en la seccion 5.3.4. Utiliza un Pipeline de Scikit-learn que combina normalizacion por StandardScaler y un clasificador SVM con kernel RBF. Los hiperparametros $C=10$ y $\gamma='scale'$ se seleccionaron como punto de partida basado en la literatura (Bi et al., 2025), pendiente de optimizacion mediante GridSearchCV en la fase de refinamiento.

7.3.1.- Ejecucion

```
python clasificador.py --csv features.csv --output modelo_svm.pkl
```

7.3.2.- Resultados de evaluacion

Durante el proceso de calibracion del clasificador por reglas se realizaron mediciones sistematicas de las metricas geometricas sobre 130+ fotogramas capturados en condiciones reales de operacion (iluminacion de interior, distancia camara-sujeto 60 cm, resolucion 640x480). Los resultados obtenidos constituyen la base empirica para la definicion de umbrales del clasificador: **Metrica Expresion Media $\pm$ DE Rango observado** COM-MEJ Neutral 0.108 ± 0.005 0.087 - 0.115 COM-MEJ Alegria 0.092 ± 0.007 0.083 - 0.115

MAR Neutral 0.595 ± 0.023 0.538 - 0.654 MAR Dolor > 0.630 (p90) umbral derivado EAR Normal 0.283 ± 0.041 0.142 - 0.384 EAR Fruncido < 0.185 umbral derivado El analisis de separabilidad entre clases revelo que la metrica MAR (Mouth Aspect Ratio) presenta un rango de variacion reducido de solo 0.116 unidades entre la expresion neutral y la apertura maxima de boca, lo que limita su capacidad discriminativa como unica senal para ALEGRIA. En contraste, la metrica COM-MEJ (diferencia de coordenada Y entre comisuras y mejillas) exhibe una separacion estadisticamente significativa entre expresion neutral (media=0.108) y sonrisa (media=0.092), con un umbral optimo de 0.100 que maximiza la precision combinada: ALEGRIA detectada correctamente en el 88% de los casos, NEUTRAL correcto en el 93%. Este hallazgo es consistente con la literatura sobre reconocimiento facial en poblaciones con variabilidad individual alta: la dependencia de MAR como unica senal para detectar alegria es insuficiente cuando la persona presenta apertura labial en reposo mayor a la media poblacional, lo que justifica la inclusion de metricas complementarias como COM- MEJ y valida la necesidad de un clasificador entrenado con datos reales del usuario objetivo (Sabater-Garriz et al., 2024). [TABLA DE RESULTADOS: Accuracy, Precision, Recall, F1-score — pendiente de completar con datos del SVM entrenado] [IMAGEN: matriz_confusion.png — pendiente de generar con clasificador.py]

7.4.- Modulo 3: Interfaz Grafica CAA (interfaz.py)

El script interfaz.py implementa la interfaz grafica de usuario descrita en la seccion 5.5. La ventana se divide en dos paneles: el panel izquierdo muestra el stream de video con los landmarks superpuestos, y el panel derecho presenta la emocion detectada como una tarjeta con icono, etiqueta de color diferenciado y el mensaje de voz asociado. El boton de reproduccion permite al cuidador activar manualmente la sintesis de voz mediante pyttsx3.

7.4.1.- Ejecucion

`pip install PyQt5 pytsx3 python interfaz.py python interfaz.py --modelo modelo_svm.pkl # con SVM entrenado`

7.4.2.- Capturas de la interfaz en operacion

La interfaz grafica CAA (interfaz.py) integra el pipeline completo en una ventana PyQt5 de dos paneles. El panel izquierdo muestra el stream de video con los landmarks superpuestos en tiempo real. El panel derecho presenta la emocion detectada mediante una tarjeta visual con icono representativo, etiqueta coloreada segun la emocion (verde para ALEGRIA, rojo para DOLOR, gris para NEUTRAL) y el mensaje de CAA asociado. Un boton de reproduccion permite al cuidador activar manualmente la sintesis de voz.

[CAPTURA: interfaz.py mostrando NEUTRAL — tarjeta gris, mensaje 'Estoy bien'] [CAPTURA: interfaz.py mostrando ALEGRIA — tarjeta verde, mensaje '¡Me siento bien!'] [CAPTURA: interfaz.py mostrando DOLOR — tarjeta roja, mensaje 'Necesito ayuda, me duele']

7.5.- Resultados del Pipeline en Tiempo Real

Las siguientes capturas documentan el funcionamiento del pipeline de extraccion de landmarks (pipeline.py) en condiciones reales de operacion sobre el hardware objetivo: laptop HP 255 G8 con procesador AMD Ryzen 5 5500U, 15 GB de RAM y GPU integrada AMD Lucienne, sin GPU dedicada.

7.5.1.- Deteccion de landmarks en tiempo real

Las siguientes capturas documentan el funcionamiento del pipeline de deteccion de landmarks (pipeline.py) en condiciones reales sobre el hardware objetivo: laptop HP 255 G8, AMD Ryzen 5 5500U, 15 GB RAM, GPU integrada AMD Lucienne, sin GPU dedicada. El sistema opera consistentemente a 30 FPS, cumpliendo el criterio de desempeno establecido en la Meta M1 del proyecto. Figura 3. Pipeline FER — expresion neutral sin lentes, vista frontal. FPS: 30.1, EAR: 0.308, MAR: 0.613.

Figura 1. Pipeline FER en operacion — expresion neutral, sin lentes. FPS: 29.9, EAR: 0.248, MAR: 0.542, BA: 1.845.

Figura 4. Pipeline FER — clasificacion DOLOR. COM-MEJ: 0.101, proxima al umbral de 0.100. FPS: 30.0.

7.5.2.- Metricas de latencia

La latencia del sistema se midio sobre 500 fotogramas consecutivos en condiciones de operacion normal. La tabla siguiente presenta los resultados por etapa del pipeline: Etapa del pipeline Latencia media Percentil 95 Herramienta Captura y conversion BGR- RGB ~12 ms ~18 ms OpenCV Deteccion landmarks MediaPipe ~18 ms ~25 ms MediaPipe Tasks Calculo metricas geometricas < 1 ms < 2 ms NumPy Clasificacion por reglas < 1 ms < 1 ms Python Actualizacion display OpenCV ~3 ms ~5 ms OpenCV TOTAL end-to-end ~34 ms ~51 ms < 500 ms ✓

La latencia total end-to-end de aproximadamente 34 ms equivale a una tasa de procesamiento de ~29 fotogramas por segundo, cumpliendo ampliamente el criterio de latencia inferior a 500 ms establecido en la Meta M3. El componente de mayor costo es la inferencia de MediaPipe (~18 ms), que opera sobre CPU gracias a la optimización XNNPACK del modelo face_landmarker.task (Google AI, 2020).

7.5.3.- Proceso de Calibración de Umbrales

Un hallazgo relevante del desarrollo es que los umbrales del clasificador no son universales sino que deben calibrarse por usuario. El proceso implementado consistió en: (1) grabación de 130 fotogramas con expresiones neutras y sonrisa exagerada; (2) cálculo de estadísticos descriptivos (media, desviación estándar, percentiles) para cada métrica geométrica; (3) identificación del umbral óptimo como la media de las medias de ambas distribuciones, maximizando la precisión combinada. Este protocolo de calibración personal es reproducible y tarda menos de 2 minutos, lo que lo hace viable para el contexto de uso clínico previsto. Este resultado valida y amplifica la hipótesis de trabajo planteada en la sección 1.5: el sistema FER basado en landmarks geométricos es viable técnicamente en hardware de consumo estándar, y la calibración personal es un paso necesario que mejora significativamente la precisión del clasificador para cada usuario específico. Esta observación será documentada como parte del análisis de viabilidad clínica (Meta M5) y constituye una contribución metodológica del presente trabajo.

7.6.- Discusión preliminar del desarrollo

El presente proyecto propone una solución tecnológica viable, reproducible y de alto impacto social para un problema crítico: la comunicación en personas con Parálisis Cerebral. A diferencia de enfoques previos que requieren infraestructura computacional especializada o datos clínicos difíciles de obtener, esta investigación adopta un enfoque pragmático que prioriza la ejecutabilidad en entornos universitarios y domésticos. Las principales aportaciones de esta investigación son:

- 20. Comparativa metodológica de clasificadores ligeros para FER: La evaluación sistemática de SVM y MLP sobre landmarks geométricos versus fine-tuning de MobileNetV2 sobre imágenes normalizadas constituye una contribución documentada al campo, especialmente relevante para contextos de escasez de datos y recursos computacionales limitados.
- 21. Pipeline de extracción de landmarks como representación intermedia: La adopción de MediaPipe Face Mesh como capa de abstracción entre la imagen bruta y el clasificador permite una representación compacta, invariante a escala e iluminación, y ejecutable en tiempo real sin GPU. Este enfoque reduce significativamente la dependencia de grandes volúmenes de datos de entrenamiento.
- 22. Análisis de viabilidad clínica documentado: El proyecto no solo desarrolla un prototipo funcional, sino que produce una hoja de ruta metodológica que identifica las brechas entre el sistema actual y un sistema clínicamente validado para expresiones atípicas de PC. Esta documentación es en sí misma una aportación para investigadores que busquen extender el trabajo con datos reales.

23. Herramienta CAA accesible y personalizable: Con metas cuantitativas claras (precisión > 80%, latencia < 500ms) y un diseño centrado en la usabilidad para cuidadores sin formación técnica, el proyecto demuestra que es posible llevar soluciones de inteligencia artificial aplicada a la salud a entornos domésticos y escolares sin infraestructura especializada. El éxito de este proyecto sentará las bases para futuras investigaciones que, contando con acceso a datos clínicos de personas con PC, puedan retomar el pipeline propuesto y extenderlo hacia un sistema de CAA clínicamente validado y de mayor impacto social.

UNIDAD VIII.- RESULTADOS EXPERIMENTALES Y PROPUESTA MULTIMODAL

Esta unidad presenta los resultados experimentales integrados de la tesis: entrenamiento de clasificadores, evaluación con GPU, interfaz CAA preliminar, hallazgos de viabilidad y propuesta multimodal con GSR, cámara y ergómetro.

Hallazgo rector

La visión facial no debe presentarse como solución universal para comunicación en Parálisis Cerebral. El resultado defendible es un prototipo experimental y una arquitectura multimodal donde cámara, GSR, contexto de terapia y observación humana se complementan.

8.1 Componentes implementados

Componente	Evidencia	Estado
Clasificador rápido SVM/MLP	files/clasificador_rapido.py; files/resultados_rapidos	Ejecutado
CNN con GPU y train/test	files/entrenar_cnn_train_test.py; RTX 5070	Ejecutado
Interfaz CAA	files/interfaz_caa.py; capturas	Implementada
GSR + cámara	files/gsr_therapy_logger.py; arduino_gsr.ino	Diseñado para prueba

8.2 Resultados SVM y MLP sobre landmarks geométricos

Modelo	Accuracy	F1 macro	AUC-ROC	F1 alegría	F1 neutral	F1 dolor
SVM	0.6885	0.6762	0.8652	0.8201	0.6196	0.5888
MLP	0.6823	0.6724	0.8592	0.819	0.6023	0.596

El SVM alcanzó accuracy de 0.6885 y AUC-ROC macro de 0.8652. El MLP obtuvo accuracy de 0.6823 y AUC-ROC macro de 0.8592. La clase alegría fue la más estable; neutral y dolor/malestar presentaron mayor confusión.




Figura 13.1 Matriz de confusión SVM.




Figura 13.2 Curvas ROC SVM/MLP.

8.3 CNN entrenada con files/train y evaluada con files/test

Modelo	GPU	Épocas	Accuracy	F1 macro	AUC-ROC
SmallEmoti onCNN	NVIDIA GeForce RTX 5070 Laptop GPU	8	0.5926	0.6011	0.8826

La CNN fue entrenada con PyTorch usando la GPU NVIDIA GeForce RTX 5070 Laptop. Aunque el accuracy fue menor que el de los clasificadores geométricos, el AUC-ROC macro alcanzó 0.8826, lo cual indica capacidad discriminativa parcial y justifica mantener el enfoque como comparación experimental.




Figura 13.3 Historial de entrenamiento CNN.




Figura 13.4 Matriz de confusión CNN.

8.4 Interfaz CAA y capturas de funcionamiento

Se construyó una interfaz que carga el modelo SVM, abre cámara 0, dibuja landmarks/contornos faciales, muestra una emoción principal y propone un mensaje de comunicación asistida. Se retiraron gráficas de probabilidad en vivo porque resultaban poco útiles para el cuidador y generaban ruido visual.



Figura 13.5 Captura de interfaz CAA durante pruebas de expresión.




Figura 13.6 Captura de interfaz CAA durante pruebas de expresión.




Figura 13.7 Captura de interfaz CAA durante pruebas de expresión.




Figura 13.8 Captura de interfaz CAA durante pruebas de expresión.




Figura 13.9 Captura de interfaz CAA durante pruebas de expresión.




Figura 13.10 Captura de interfaz CAA durante pruebas de expresión.




Figura 13.11 Captura de interfaz CAA durante pruebas de expresión.

8.5 Limitaciones detectadas

- Las expresiones faciales en personas con Parálisis Cerebral pueden ser atípicas, limitadas o inconsistentes.
- Los datasets públicos no representan de forma suficiente expresiones clínicas de dolor en PC.
- La cámara puede fallar ante lentes, iluminación, pose, boca muy abierta o movimientos involuntarios.
- La salida del modelo debe tratarse como alerta auxiliar, no diagnóstico ni comunicación autónoma.
- El desempeño actual no permite afirmar una herramienta clínicamente validada.

8.6 Replanteamiento multimodal: GSR, cámara y ergómetro

Dado que el proyecto nace como complemento de un ergómetro de rehabilitación, el avance propone registrar datos fisiológicos mediante un sensor GSR conectado a Arduino. El sistema `gsr_therapy_logger.py` permite leer el puerto serial, abrir cámara y guardar capturas sincronizadas cuando se presentan cambios de señal o eventos manuales.

Señal	Aporta	Limitación
Cámara	Evidencia visual y facial.	No interpreta expresiones atípicas de forma universal.
GSR/EDA	Activación fisiológica durante terapia.	No distingue por sí sola dolor, estrés o esfuerzo.
Ergómetro	Contexto de rehabilitación y carga física.	Debe sincronizarse con los otros datos.
Terapeuta/ cuidador	Interpretación contextual.	Puede ser subjetiva, pero es necesaria.

8.7 Trabajo futuro

1. Conectar mañana el sensor GSR al Arduino y registrar una sesión piloto.
2. Sincronizar capturas de cámara con picos de GSR durante terapia.
3. Agregar eventos del ergómetro: inicio, descanso, carga, fatiga y finalización.
4. Desarrollar una pantalla de análisis posterior para revisar cada evento fisiológico con su imagen.
5. Diseñar protocolo ético antes de trabajar con personas con Parálisis Cerebral.
6. Explorar métodos CAA alternativos: mirada, cabeza, switch/escaneo y confirmación del cuidador.

8.8 Conclusión del avance técnico

El proyecto no pierde viabilidad; cambia de una promesa excesiva a una conclusión investigativa más fuerte. La visión facial aislada es insuficiente para comunicación universal en PC, pero el pipeline desarrollado demuestra viabilidad técnica como componente de un sistema multimodal de apoyo a rehabilitación. La tesis se fortalece al reconocer límites, mostrar resultados reales y proponer integración de GSR, cámara, ergómetro y observación humana.

REFERENCIAS BIBLIOGRÁFICAS

- Bi, K., Liao, J., Gao, D., & Yin, R. (2025). A comparative study on facial expression recognition using MobileNetV2, VGG-16, ResNet and Swin Transformer. *SPIE Proceedings*.
<https://doi.org/10.1117/12.3054321>
- Chen, Y., Yang, X., Liu, Z., & Wang, C. (2022). Generative adversarial networks in medical image augmentation: A review. *Computers in Biology and Medicine*, 149, 106063. <https://doi.org/10.1016/j.compbimed.2022.106063>
- Gaya-Morey, F. X., Manresa-Yee, C., Buades-Rubio, J. M., & Ramis, S. (2024). Assessing the efficacy of deep learning approaches for facial expression recognition in individuals with intellectual disabilities. *arXiv preprint arXiv:2401.11877*.
- Google AI. (2020). MediaPipe Face Mesh: Real-time face landmark detection. Google AI Blog.
<https://ai.googleblog.com/2020/04/mediapipe-face-mesh-real-time-face.html>
- Goodfellow, I. J., Erhan, D., Carrier, P. L., Courville, A., Mirza, M., Hamner, B., Cukierski, W., Tang, Y., Thaler, D., Lee, D.-H., Zhou, Y., Ramaiah, C., Feng, F., Li, R., Wang, X., Athanasakis, D., Shawe-Taylor, J., Milakov, M., Park, J., & Bengio, Y. (2013). Challenges in representation learning: A report on three machine learning contests. *Neural Networks*, 64, 59–63. <https://doi.org/10.1016/j.neunet.2014.09.005>
- Kristoffersson, E., Svensson, I., Ek, L., Himmelmann, K., & Danielsson, H. (2020). Communication ability and communication methods in children with cerebral palsy: A systematic review. *Developmental Medicine & Child Neurology*, 62(7), 788–796. <https://doi.org/10.1111/dmcn.14480>
- Nan, Y., Ju, J., Hua, Q., Zhang, H., & Wang, B. (2022). A-MobileNet: An approach of facial expression recognition. *Alexandria Engineering Journal*, 61(12), 9789–9799. <https://doi.org/10.1016/j.aej.2022.03.009>
- Peters, B., Bieker, G., Hacker, K. B., Leister, E., Mehta, J. L., Peleg, R., Schwartz, E., & Bryen, D. N. (2022). A systematic review of research on augmentative and alternative communication-brain-computer interface (AAC-BCI) systems. *Assistive Technology*, 34(4), 415–427. <https://doi.org/10.1080/10400435.2020.1852948>
- Sabater-Gárriz, A., Montoya-Murillo, G., Soro-Camats, E., & Martino-Alba, R. (2024). Automated facial recognition system using deep learning for pain assessment in individuals with cerebral palsy. *Journal of NeuroEngineering and Rehabilitation*, 21(1), 1–12. <https://doi.org/10.1186/s12984-024-01364-9>
- Sabater-Gárriz, A., Montoya-Murillo, G., & Soro-Camats, E. (2025). Design of a mobile application based on artificial intelligence for pain assessment in non-communicative individuals with cerebral palsy. *Computer Methods and Programs in Biomedicine*.
<https://doi.org/10.1016/j.cmpb.2025.108180>
- Sennott, S. C., Koch, M. E., & Reed, P. (2019). AAC and artificial intelligence (AI). *Augmentative and Alternative Communication*, 35(2), 115–125.
<https://doi.org/10.1080/07434618.2019.1577991>
- van der Veen, S., Schippers, A., Kooijmans, T., Haak, S., & Eeftink-Smeets, M. (2022). Artificial intelligence to improve rehabilitation care for children with developmental conditions: Some ethical considerations. *Developmental Medicine & Child Neurology*, 64(10), 1216–1222. <https://doi.org/10.1111/dmcn.15308>
- Yoonessi, S., Parvaresh-Rizi, M., Shojaei-Fard, R., Sepehri, M., Baecchi, P., & Raoufy, M. R. (2025). Facial expression deep learning algorithms in the detection of neurological disorders. *Biomedical Engineering Online*, 24(1), 1–15.
<https://doi.org/10.1186/s12938-025-01339-4>
- Hernández Sampieri, R., Fernández Collado, C., & Baptista Lucio, P. (2014). *Metodología de la investigación* (6.ª ed.). McGraw-Hill Education. Trujillo Hernández, B.

(s.f.). Variables y escalas de medición. En Capítulo VI (pp. 81–89). Universidad de Colima. Yu, I. C., Lee, H. Y., Chen, Y. C., & Liu, S. Y. (2025). Development of nonverbal communication behavior model using facial expression recognition and deep learning. *Cogent Engineering*, 12(1), 2448059. <https://doi.org/10.1080/23311916.2024.2448059> Chen, Y., et al. (2022). Generative Adversarial Networks in Medical Image Augmentation: A Review. *Computers in Biology and Medicine*, 149, 106063.

Gaya-Morey, F. X., et al. (2024). Assessing the Efficacy of Deep Learning Approaches for Facial Expression Recognition in Individuals with Intellectual Disabilities. *arXiv preprint arXiv:2401.11877*. Google AI. (2020). MediaPipe Face Mesh: Real-time Face Landmark Detection. Google AI Blog. Kristoffersson, E., et al. (2020). Communication ability and communication methods in children with cerebral palsy: A systematic review. *Developmental Medicine & Child Neurology*, 62(7), 788– 796. Nan, Y., Ju, J., Hua, Q., Zhang, H., & Wang, B. (2022). A-MobileNet: An approach of facial expression recognition. *Alexandria Engineering Journal*, 61(12), 9789–9799. Peters, B., et al. (2022). A systematic review of research on augmentative and alternative communication-brain-computer interface (AAC-BCI) systems. *Assistive Technology*, 34(4), 415– 427. Sabater-Gárriz, A., et al. (2024). Automated facial recognition system using deep learning for pain assessment in individuals with cerebral palsy. *Journal of NeuroEngineering and Rehabilitation*, 21(1), 1–12. Sabater-Gárriz, A., et al. (2025). Design of a mobile application based on artificial intelligence for pain assessment in non-communicative individuals with cerebral palsy. *Computer Methods and Programs in Biomedicine*. Sennott, S. C., et al. (2019). AAC and Artificial Intelligence (AI). *Augmentative and Alternative Communication*, 35(2), 115–125. van der Veen, S., et al. (2022). Artificial intelligence to improve rehabilitation care for children with developmental conditions: Some ethical considerations. *Developmental Medicine & Child Neurology*, 64(10), 1216–1222. Yoonessi, S., et al. (2025). Facial expression deep learning algorithms in the detection of neurological disorders. *Biomedical Engineering Online*, 24(1), 1–15. Yu, I. C., et al. (2025). Development of nonverbal communication behavior model using facial expression recognition and deep learning. *Cogent Engineering*, 12(1), 2448059.